# Lab 9 - PCC177/BCC406

## REDES NEURAIS E APRENDIZAGEM EM PROFUNDIDADE

## NLP

### Prof. Eduardo e Prof. Pedro

Objetivos:

- Implementar técncias de PLN para resolver um problema de classificação de texto tóxico em portugues.

Data da entrega : Fim do período

- Complete o código (marcado com ToDo) e quando requisitado, escreva textos diretamente nos notebooks. Onde tiver *None*, substitua pelo seu código.
- Execute todo notebook e salve tudo em um PDF **nomeado** como "NomeSobrenome-Lab.pdf"
- Envie o PDF via google FORM

Este notebook é baseado em tensorflow e Keras.

## Importando bibliotecas e preparando o ambiente

Importando as bibliotecas

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import seaborn as sns
import tensorflow as tf

from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import classification_report, confusion_matrix
from tensorflow.keras.preprocessing.text import Tokenizer
from tensorflow.keras.preprocessing.sequence import pad_sequences
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Embedding, Flatten
```

Montando o seu drive no colab.

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Mounted at /content/drive
```

Vamos carregar a base de dados "*Brazilian Portuguese Hatespeech dataset*". Para detalhes sobre o dataset e o problema em si, veja o link do Kaggle.

```
# Ler o arquivo CSV hate_speech_binary_classification_train.csv dentro da pasta de dataset do drive compartilhado.
# Substitua o 'caminho_do_arquivo_treino.csv' pelo caminho real do seu arquivo CSV
dados = pd.read_csv('/content/drive/MyDrive/datasets/hate_speech_binary_classification_train.csv')

# Ler o arquivo CSV hate_speech_binary_classification_test.csv dentro da pasta de dataset do drive compartilhado.
# Substitua o 'caminho_do_arquivo_teste.csv' pelo caminho real do seu arquivo CSV
dados_teste = pd.read_csv('/content/drive/MyDrive/datasets/hate_speech_binary_classification_test.csv')
```

Mostrar as primeiras linhas do DataFrame

```
print(dados.head())
```

```
                                                text  \
0  -Odeio feministas só falam merda\n-Vamos fazer...
1  CHEGOU DANDO CANTADA NO CARNAVAL:\n#CarnavalSe...
2  Diferença entre 'manifestante' e 'terrorista'....
3  É legal pra um presidente 'grampear' uma corri...
4  não há como negar a biologia....por mais que a...

                                             protext  class
```

```
0  -Odeio feministas só falam merda -Vamos fazer ...      1
1  CHEGOU DANDO CANTADA NO CARNAVAL: #CarnavalSem...      0
2  Diferença entre 'manifestante' e 'terrorista'....      1
3  É legal pra um presidente 'grampear' uma corri...      0
4  não há como negar a biologia....por mais que a...      0
```

## Pré-processando os dados

Selecionando colunas específicas

```
dados_brutos = dados.iloc[:, 0]
X = dados.iloc[:, 1] # Coluna dos dados pré-processados
y = dados.iloc[:, 2] # Coluna dos rótulos

X_test = dados_teste.iloc[:, 1]  # Coluna dos dados pré-processados
y_test = dados_teste.iloc[:, 2]  # Coluna dos rótulos
```

Mostrar as primeiras linhas de cada coluna

```
print("Dados brutos:")
print(dados_brutos.head())
print("\nRótulos:")
print(y.head())
print("\nDados preprocessados:")
print(X.head())
```

```
Dados brutos:
0    -Odeio feministas só falam merda\n-Vamos fazer...
1    CHEGOU DANDO CANTADA NO CARNAVAL:\n#CarnavalSe...
2    Diferença entre 'manifestante' e 'terrorista'....
3    É legal pra um presidente 'grampear' uma corri...
4    não há como negar a biologia....por mais que a...
Name: text, dtype: object

Rótulos:
0    1
1    0
2    1
3    0
4    0
Name: class, dtype: int64

Dados preprocessados:
0    -Odeio feministas só falam merda -Vamos fazer ...
1    CHEGOU DANDO CANTADA NO CARNAVAL: #CarnavalSem...
2    Diferença entre 'manifestante' e 'terrorista'....
3    É legal pra um presidente 'grampear' uma corri...
4    não há como negar a biologia....por mais que a...
Name: protext, dtype: object
```

## Uma implementação ingênua para o problema

Abaixo uma implementação ingênua para o problema. Ela é ingênua por que desconsidera a ordem das palavras no texto. Tente endendê-la e execute o treinamento.

### Pré-processamento

Primeira coisa é fixar as sementes para garantir a reproducibilidade dos resultados

```
np.random.seed(94)
tf.random.set_seed(94)
```

Codificação dos rótulos para 0 e 1

```
encoder = LabelEncoder()
y = encoder.fit_transform(y)
y_test = encoder.transform(y_test)
```

Tokenização e sequenciamento dos textos

```
max_length = 280  # Define o tamanho máximo das sequências
vocab_size = 100000  # Define o tamanho do vocabulário

tokenizer = Tokenizer(num_words=vocab_size, oov_token='<OOV>')
tokenizer.fit_on_texts(X)
# Tokenização e sequenciamento dos textos de treino
sequences = tokenizer.texts_to_sequences(X)
padded_sequences = pad_sequences(sequences, maxlen=max_length, padding='post', truncating='post')

# Tokenização e sequenciamento dos textos de teste
sequences_test = tokenizer.texts_to_sequences(X_test)
padded_sequences_test = pad_sequences(sequences_test, maxlen=max_length, padding='post', truncating='post')
```

Divisão dos dados em conjuntos de treino e validação

```
X_train, X_val, y_train, y_val = train_test_split(padded_sequences, y, test_size=0.2, random_state=42)
```

## Definição e treinamento do modelo

Definição do modelo

```
embedding_dim = 16

model = Sequential([
    Embedding(vocab_size, embedding_dim, input_length=max_length),
    Flatten(),
    Dense(32, activation='relu'),
    Dense(1, activation='sigmoid')
])
```

Compilação do modelo

```
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
```

Visualizando os dados

```
model.summary()
```

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 embedding (Embedding)       (None, 280, 16)           1600000

 flatten (Flatten)           (None, 4480)              0

 dense (Dense)               (None, 32)                143392

 dense_1 (Dense)             (None, 1)                 33

=================================================================
Total params: 1743425 (6.65 MB)
Trainable params: 1743425 (6.65 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
```

Treinamento do modelo

```
epochs = 5
history = model.fit(X_train, y_train, epochs=epochs, validation_data=(X_val, y_val), verbose=2)
```

```
Epoch 1/5
72/72 - 11s - loss: 0.6944 - accuracy: 0.4965 - val_loss: 0.6931 - val_accuracy: 0.5035 - 11s/epoch - 150ms/step
Epoch 2/5
72/72 - 4s - loss: 0.6932 - accuracy: 0.4904 - val_loss: 0.6931 - val_accuracy: 0.5035 - 4s/epoch - 58ms/step
Epoch 3/5
72/72 - 3s - loss: 0.6932 - accuracy: 0.4869 - val_loss: 0.6932 - val_accuracy: 0.4965 - 3s/epoch - 36ms/step
Epoch 4/5
72/72 - 1s - loss: 0.6932 - accuracy: 0.4930 - val_loss: 0.6931 - val_accuracy: 0.5035 - 1s/epoch - 17ms/step
Epoch 5/5
72/72 - 1s - loss: 0.6932 - accuracy: 0.4913 - val_loss: 0.6931 - val_accuracy: 0.4965 - 1s/epoch - 16ms/step
```

Plotando as curvas de loss

```
plt.figure(figsize=(8, 6))
plt.plot(history.history['loss'], label='Training Loss')
plt.plot(history.history['val_loss'], label='Validation Loss')
plt.title('Training and Validation Losses')
plt.xlabel('Epoch')
plt.ylabel('Loss')
plt.legend()
plt.show()
```

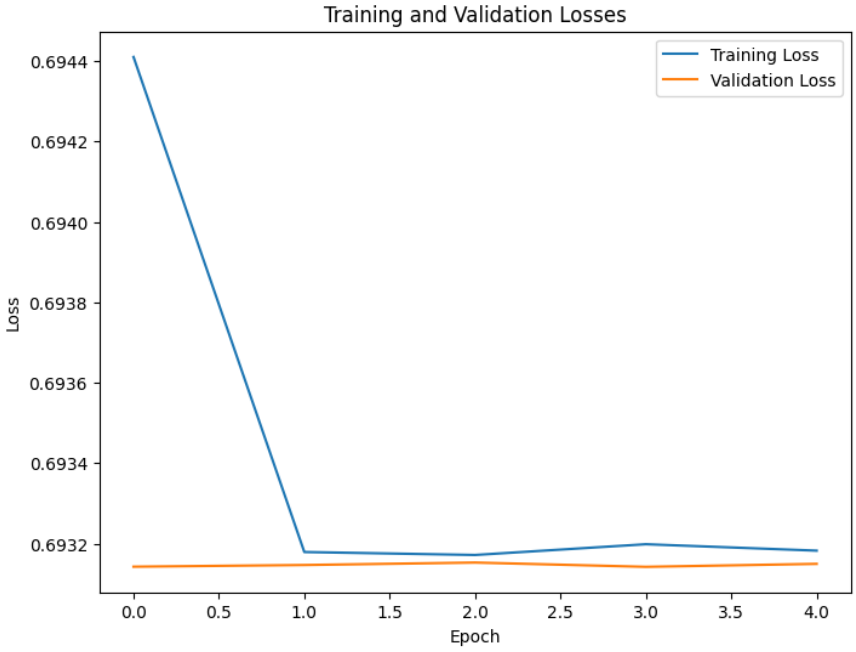


## Avaliação do modelo

### Avaliar o modelo nos dados de teste

```
# Fazendo previsões no conjunto de teste
y_pred_prob = model.predict(padded_sequences_test)
y_pred = (y_pred_prob > 0.5).astype(int)

loss, accuracy = model.evaluate(padded_sequences_test, y_test, verbose=2)
print(f"Perda nos dados de teste: {loss:.4f}")
print(f"Acurácia nos dados de teste: {accuracy:.4f}")
```

```
23/23 [==============================] - 0s 1ms/step
23/23 - 0s - loss: 0.6931 - accuracy: 0.5000 - 54ms/epoch - 2ms/step
Perda nos dados de teste: 0.6931
Acurácia nos dados de teste: 0.5000
```

### Gerando o relatório de classificação

```
report = classification_report(y_test, y_pred, target_names=encoder.classes_, output_dict=True)
```

```
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are i
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are i
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score are i
  _warn_prf(average, modifier, msg_start, len(result))
```

### Plotando os resultados

```
print("Classificação Report:")
for label, metrics in report.items():
    if label == 'accuracy':
        continue
    print(f"Class: {label}")
    print(f"\tPrecision: {metrics['precision']}")
    print(f"\tRecall: {metrics['recall']}")
```

```
    print(f"\tF1-score: {metrics['f1-score']}")
print(f"Macro Avg: {report['macro avg']}")
print(f"Weighted Avg: {report['weighted avg']}")
```

```
Classificação Report:
Class: 0
        Precision: 0.0
        Recall: 0.0
        F1-score: 0.0
Class: 1
        Precision: 0.5
        Recall: 1.0
        F1-score: 0.6666666666666666
Class: macro avg
        Precision: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Class: weighted avg
        Precision: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Macro Avg: {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
Weighted Avg: {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
```

Plotando a matriz de confusão

```
cm = confusion_matrix(y_test, y_pred)
plt.figure(figsize=(6, 6))
sns.heatmap(cm, annot=True, fmt='d', cmap='Blues')
plt.xlabel('Predicted')
plt.ylabel('Actual')
plt.title('Confusion Matrix')
plt.show()
```

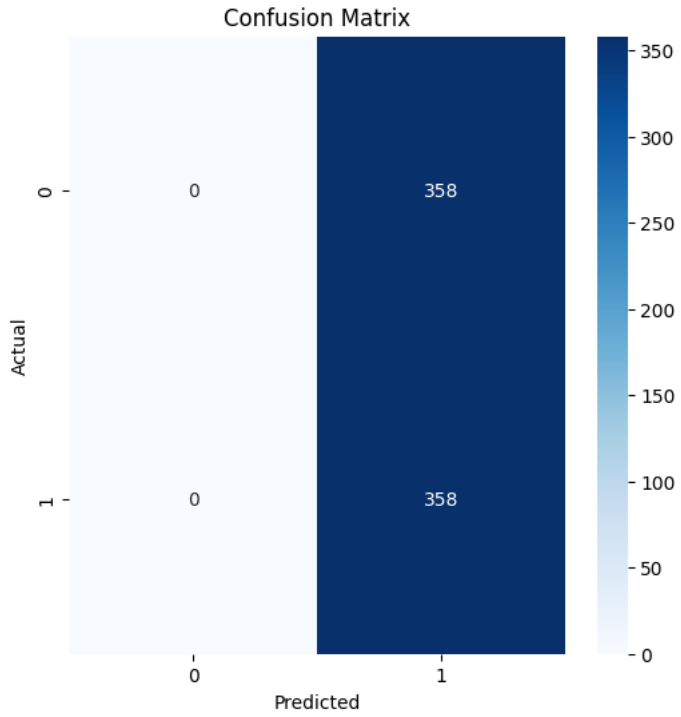


Previsões do modelo

```
y_pred = (model.predict(padded_sequences_test) > 0.5).astype("int32")
```

```
23/23 [==============================] - 0s 2ms/step
```

## *ToDo*: O que você pode analisar dos resultados acima?

O conjunto de dados apresenta um desbalanceamento significativo entre as classes, com a classe 1 (Tóxico) sendo mais predominante, evidenciado pel

Ao avaliar o desempenho diferencial entre as classes, observamos que a classe 0 (Não Tóxico) possui uma alta precisão (80%), indicando que o model
No entanto, o recall para a classe 0 é muito baixo (7.82%), sugerindo que o modelo está perdendo muitas instâncias não tóxicas, o que pode ser prc

Para a classe 1 (Tóxico), a precisão é menor (51.54%), indicando que há uma chance menor de o modelo estar correto quando prevê que um texto é tó
No entanto, o recall para a classe 1 é alto (98.04%), indicando que o modelo está efetivamente identificando a maioria dos textos tóxicos.

As médias macro e ponderada indicam que o desempenho médio do modelo é razoável, mas a ênfase nas métricas da classe majoritária pode mascarar que

Ao analisar o F1-score, observamos que, enquanto a classe 1 (Tóxico) mostra um equilíbrio razoável entre precisão e recall (67.56%), a classe 0 (N

## Faça o mesmo processamento utilizando GRU

Pelo menos duas camadas de GRU

```
from tensorflow.keras.layers import GRU

# Definição do modelo com camadas GRU
model_gru = Sequential([
    Embedding(vocab_size, embedding_dim, input_length=max_length),
    GRU(32, return_sequences=True),
    GRU(32),
    Dense(32, activation='relu'),
    Dense(1, activation='sigmoid')
])

# Compilação do modelo
model_gru.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
model_gru.summary()

# Treinamento do modelo
history_gru = model_gru.fit(X_train, y_train, epochs=5, validation_data=(X_val, y_val), verbose=2)

# Avaliação do modelo nos dados de teste
loss_gru, accuracy_gru = model_gru.evaluate(padded_sequences_test, y_test, verbose=2)
print(f"Perda nos dados de teste (GRU): {loss_gru:.4f}")
print(f"Acurácia nos dados de teste (GRU): {accuracy_gru:.4f}")

# Fazendo previsões no conjunto de teste
y_pred_gru = (model_gru.predict(padded_sequences_test) > 0.5).astype(int)

# Gerando o relatório de classificação sem warnings
report_gru = classification_report(y_test, y_pred_gru, target_names=encoder.classes_, output_dict=True)
print("Relatório de Classificação (GRU):")
for label, metrics in report_gru.items():
    if label == 'accuracy':
        continue
    print(f"Classe: {label}")
    print(f"\tPrecisão: {metrics['precision']}")
    print(f"\tRecall: {metrics['recall']}")
    print(f"\tF1-score: {metrics['f1-score']}")
print(f"Média Macro (GRU): {report_gru['macro avg']}")
print(f"Média Ponderada (GRU): {report_gru['weighted avg']}")
```

```
 Layer (type)                Output Shape              Param #
=================================================================
 embedding_1 (Embedding)     (None, 280, 16)           1600000

 gru (GRU)                   (None, 280, 32)           4800

 gru_1 (GRU)                 (None, 32)                6336

 dense_2 (Dense)             (None, 32)                1056

 dense_3 (Dense)             (None, 1)                 33

=================================================================
Total params: 1612225 (6.15 MB)
Trainable params: 1612225 (6.15 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
Epoch 1/5
72/72 - 11s - loss: 0.6935 - accuracy: 0.4991 - val_loss: 0.6931 - val_accuracy: 0.5035 - 11s/epoch - 159ms/step
Epoch 2/5
72/72 - 3s - loss: 0.6932 - accuracy: 0.4878 - val_loss: 0.6931 - val_accuracy: 0.4965 - 3s/epoch - 43ms/step
Epoch 3/5
72/72 - 3s - loss: 0.6932 - accuracy: 0.4860 - val_loss: 0.6932 - val_accuracy: 0.4965 - 3s/epoch - 44ms/step
Epoch 4/5
72/72 - 2s - loss: 0.6932 - accuracy: 0.4860 - val_loss: 0.6932 - val_accuracy: 0.4965 - 2s/epoch - 32ms/step
```

```
72/72 - 2s - loss: 0.6932 - accuracy: 0.5009 - val_loss: 0.6932 - val_accuracy: 0.4965 - 2s/epoch - 26ms/step
23/23 - 0s - loss: 0.6931 - accuracy: 0.5000 - 195ms/epoch - 8ms/step
Perda nos dados de teste (GRU): 0.6931
Acurácia nos dados de teste (GRU): 0.5000
23/23 [==============================] - 1s 8ms/step
Relatório de Classificação (GRU):
Classe: 0
        Precisão: 0.0
        Recall: 0.0
        F1-score: 0.0
Classe: 1
        Precisão: 0.5
        Recall: 1.0
        F1-score: 0.6666666666666666
Classe: macro avg
        Precisão: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Classe: weighted avg
        Precisão: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Média Macro (GRU): {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
Média Ponderada (GRU): {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
```

## Faça o mesmo processamento utilizando LSTM

Pelo menos duas camadas de LSTM

```
from tensorflow.keras.layers import LSTM

# Definição do modelo com camadas LSTM
model_lstm = Sequential([
    Embedding(vocab_size, embedding_dim, input_length=max_length),
    LSTM(32, return_sequences=True),
    LSTM(32),
    Dense(32, activation='relu'),
    Dense(1, activation='sigmoid')
])

# Compilação do modelo
model_lstm.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
model_lstm.summary()

# Treinamento do modelo
history_lstm = model_lstm.fit(X_train, y_train, epochs=5, validation_data=(X_val, y_val), verbose=2)

# Avaliação do modelo nos dados de teste
loss_lstm, accuracy_lstm = model_lstm.evaluate(padded_sequences_test, y_test, verbose=2)
print(f"Perda nos dados de teste (LSTM): {loss_lstm:.4f}")
print(f"Acurácia nos dados de teste (LSTM): {accuracy_lstm:.4f}")

# Fazendo previsões no conjunto de teste
y_pred_lstm = (model_lstm.predict(padded_sequences_test) > 0.5).astype(int)

# Gerando o relatório de classificação
report_lstm = classification_report(y_test, y_pred_lstm, target_names=encoder.classes_, output_dict=True)
print("Relatório de Classificação (LSTM):")
for label, metrics in report_lstm.items():
    if label == 'accuracy':
        continue
    print(f"Classe: {label}")
    print(f"\tPrecisão: {metrics['precision']}")
    print(f"\tRecall: {metrics['recall']}")
    print(f"\tF1-score: {metrics['f1-score']}")
print(f"Média Macro (LSTM): {report_lstm['macro avg']}")
print(f"Média Ponderada (LSTM): {report_lstm['weighted avg']}")
```

```
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 embedding_2 (Embedding)     (None, 280, 16)           1600000

 lstm (LSTM)                 (None, 280, 32)           6272
```

```
 lstm_1 (LSTM)               (None, 32)                8320

 dense_4 (Dense)             (None, 32)                1056

 dense_5 (Dense)             (None, 1)                 33

=================================================================
Total params: 1615681 (6.16 MB)
Trainable params: 1615681 (6.16 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
Epoch 1/5
72/72 - 11s - loss: 0.6935 - accuracy: 0.4851 - val_loss: 0.6932 - val_accuracy: 0.4965 - 11s/epoch - 155ms/step
Epoch 2/5
72/72 - 4s - loss: 0.6934 - accuracy: 0.4921 - val_loss: 0.6931 - val_accuracy: 0.4965 - 4s/epoch - 51ms/step
Epoch 3/5
72/72 - 3s - loss: 0.6935 - accuracy: 0.4799 - val_loss: 0.6932 - val_accuracy: 0.4965 - 3s/epoch - 48ms/step
Epoch 4/5
72/72 - 3s - loss: 0.6936 - accuracy: 0.4991 - val_loss: 0.6932 - val_accuracy: 0.4965 - 3s/epoch - 40ms/step
Epoch 5/5
72/72 - 2s - loss: 0.6933 - accuracy: 0.4913 - val_loss: 0.6932 - val_accuracy: 0.4965 - 2s/epoch - 28ms/step
23/23 - 0s - loss: 0.6931 - accuracy: 0.5000 - 204ms/epoch - 9ms/step
Perda nos dados de teste (LSTM): 0.6931
Acurácia nos dados de teste (LSTM): 0.5000
23/23 [==============================] - 1s 9ms/step
Relatório de Classificação (LSTM):
Classe: 0
        Precisão: 0.0
        Recall: 0.0
        F1-score: 0.0
Classe: 1
        Precisão: 0.5
        Recall: 1.0
        F1-score: 0.6666666666666666
Classe: macro avg
        Precisão: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Classe: weighted avg
        Precisão: 0.25
        Recall: 0.5
        F1-score: 0.3333333333333333
Média Macro (LSTM): {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
Média Ponderada (LSTM): {'precision': 0.25, 'recall': 0.5, 'f1-score': 0.3333333333333333, 'support': 716}
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
/usr/local/lib/python3.10/dist-packages/sklearn/metrics/_classification.py:1344: UndefinedMetricWarning: Precision and F-score ar
  _warn_prf(average, modifier, msg_start, len(result))
```

## Faça o mesmo processamento utilizando GRU Bi-direcionais

Pelo menos duas camadas de GRU bi-direcionais

```
from tensorflow.keras.layers import Bidirectional

# Definição do modelo com camadas GRU bidirecionais
model_gru_bidirectional = Sequential([
    Embedding(vocab_size, embedding_dim, input_length=max_length),
    Bidirectional(GRU(32, return_sequences=True)),
    Bidirectional(GRU(32)),
    Dense(32, activation='relu'),
    Dense(1, activation='sigmoid')
])

# Compilação do modelo
model_gru_bidirectional.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
model_gru_bidirectional.summary()

# Treinamento do modelo
history_gru_bidirectional = model_gru_bidirectional.fit(X_train, y_train, epochs=5, validation_data=(X_val, y_val), verbose=2)

# Avaliação do modelo nos dados de teste
loss_gru_bidirectional, accuracy_gru_bidirectional = model_gru_bidirectional.evaluate(padded_sequences_test, y_test, verbose=2)
print(f"Perda nos dados de teste (GRU Bidirecional): {loss_gru_bidirectional:.4f}")
print(f"Acurácia nos dados de teste (GRU Bidirecional): {accuracy_gru_bidirectional:.4f}")

# Fazendo previsões no conjunto de teste
y_pred_gru_bidirectional = (model_gru_bidirectional.predict(padded_sequences_test) > 0.5).astype(int)

# Gerando o relatório de classificação
report_gru_bidirectional = classification_report(y_test, y_pred_gru_bidirectional, target_names=encoder.classes_, output_dict=True)
```

```
report_gru_bidirectional = classification_report(y_test, y_pred_gru_bidirectional, target_names=encoder.classes_, output_dict=True)
print("Relatório de Classificação (GRU Bidirecional):")
for label, metrics in report_gru_bidirectional.items():
    if label == 'accuracy':
        continue
    print(f"Classe: {label}")
    print(f"\tPrecisão: {metrics['precision']}")
    print(f"\tRecall: {metrics['recall']}")
    print(f"\tF1-score: {metrics['f1-score']}")
print(f"Média Macro (GRU Bidirecional): {report_gru_bidirectional['macro avg']}")
print(f"Média Ponderada (GRU Bidirecional): {report_gru_bidirectional['weighted avg']}")
```

```
Model: "sequential_3"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 embedding_3 (Embedding)     (None, 280, 16)           1600000

 bidirectional (Bidirection  (None, 280, 64)           9600
 al)

 bidirectional_1 (Bidirecti  (None, 64)                18816
 onal)

 dense_6 (Dense)             (None, 32)                2080

 dense_7 (Dense)             (None, 1)                 33

=================================================================
Total params: 1630529 (6.22 MB)
Trainable params: 1630529 (6.22 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
Epoch 1/5
72/72 - 16s - loss: 0.6920 - accuracy: 0.5210 - val_loss: 0.6861 - val_accuracy: 0.5175 - 16s/epoch - 221ms/step
Epoch 2/5
72/72 - 5s - loss: 0.5525 - accuracy: 0.7286 - val_loss: 0.6650 - val_accuracy: 0.6451 - 5s/epoch - 72ms/step
Epoch 3/5
72/72 - 4s - loss: 0.2551 - accuracy: 0.9056 - val_loss: 0.8255 - val_accuracy: 0.6573 - 4s/epoch - 55ms/step
Epoch 4/5
72/72 - 3s - loss: 0.0950 - accuracy: 0.9690 - val_loss: 1.1565 - val_accuracy: 0.6346 - 3s/epoch - 43ms/step
Epoch 5/5
72/72 - 3s - loss: 0.0377 - accuracy: 0.9891 - val_loss: 1.5600 - val_accuracy: 0.6364 - 3s/epoch - 46ms/step
23/23 - 0s - loss: 1.5936 - accuracy: 0.6397 - 477ms/epoch - 21ms/step
Perda nos dados de teste (GRU Bidirecional): 1.5936
Acurácia nos dados de teste (GRU Bidirecional): 0.6397
23/23 [==============================] - 2s 16ms/step
Relatório de Classificação (GRU Bidirecional):
Classe: 0
        Precisão: 0.6388888888888888
        Recall: 0.6424581005586593
        F1-score: 0.6406685236768802
Classe: 1
        Precisão: 0.6404494382022472
        Recall: 0.6368715083798883
        F1-score: 0.638655462184874
Classe: macro avg
        Precisão: 0.639669163545568
        Recall: 0.6396648044692738
        F1-score: 0.6396619929308771
Classe: weighted avg
        Precisão: 0.639669163545568
        Recall: 0.6396648044692738
        F1-score: 0.6396619929308771
Média Macro (GRU Bidirecional): {'precision': 0.639669163545568, 'recall': 0.6396648044692738, 'f1-score': 0.6396619929308771, 'supp
Média Ponderada (GRU Bidirecional): {'precision': 0.639669163545568, 'recall': 0.6396648044692738, 'f1-score': 0.6396619929308771,
```

## Faça o mesmo processamento utilizando LSTM Bi-direcionais

Pelo menos duas camadas de LSTM Bi-direcionais

## Faça o mesmo processamento utilizando redes recorrentes bi-direcionais e profundas

Pelo menos quatro camadas de GRU/LSTM bi-direcionais (ou não)

```
# Definição do modelo com camadas LSTM bidirecionais
model_lstm_bidirectional = Sequential([
    Embedding(vocab_size, embedding_dim, input_length=max_length),
    Bidirectional(LSTM(32, return_sequences=True)),
    Bidirectional(LSTM(32)),
    Dense(32, activation='relu'),
    Dense(1, activation='sigmoid')
])

# Compilação do modelo
model_lstm_bidirectional.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
model_lstm_bidirectional.summary()

# Treinamento do modelo
history_lstm_bidirectional = model_lstm_bidirectional.fit(X_train, y_train, epochs=5, validation_data=(X_val, y_val), verbose=2)

# Avaliação do modelo nos dados de teste
loss_lstm_bidirectional, accuracy_lstm_bidirectional = model_lstm_bidirectional.evaluate(padded_sequences_test, y_test, verbose=2)
print(f"Perda nos dados de teste (LSTM Bidirecional): {loss_lstm_bidirectional:.4f}")
print(f"Acurácia nos dados de teste (LSTM Bidirecional): {accuracy_lstm_bidirectional:.4f}")

# Fazendo previsões no conjunto de teste
y_pred_lstm_bidirectional = (model_lstm_bidirectional.predict(padded_sequences_test) > 0.5).astype(int)

# Gerando o relatório de classificação
report_lstm_bidirectional = classification_report(y_test, y_pred_lstm_bidirectional, target_names=encoder.classes_, output_dict=True)
print("Relatório de Classificação (LSTM Bidirecional):")
for label, metrics in report_lstm_bidirectional.items():
    if label == 'accuracy':
        continue
    print(f"Classe: {label}")
    print(f"\tPrecisão: {metrics['precision']}")
    print(f"\tRecall: {metrics['recall']}")
    print(f"\tF1-score: {metrics['f1-score']}")
print(f"Média Macro (LSTM Bidirecional): {report_lstm_bidirectional['macro avg']}")
print(f"Média Ponderada (LSTM Bidirecional): {report_lstm_bidirectional['weighted avg']}")
```

```
Model: "sequential_4"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 embedding_4 (Embedding)     (None, 280, 16)           1600000

 bidirectional_2 (Bidirecti  (None, 280, 64)           12544
 onal)

 bidirectional_3 (Bidirecti  (None, 64)                24832
 onal)

 dense_8 (Dense)             (None, 32)                2080

 dense_9 (Dense)             (None, 1)                 33

=================================================================
Total params: 1639489 (6.25 MB)
Trainable params: 1639489 (6.25 MB)
Non-trainable params: 0 (0.00 Byte)
_________________________________________________________________
Epoch 1/5
72/72 - 17s - loss: 0.6866 - accuracy: 0.5428 - val_loss: 0.6516 - val_accuracy: 0.6206 - 17s/epoch - 232ms/step
Epoch 2/5
72/72 - 5s - loss: 0.4895 - accuracy: 0.7649 - val_loss: 0.7447 - val_accuracy: 0.6573 - 5s/epoch - 68ms/step
Epoch 3/5
72/72 - 8s - loss: 0.2213 - accuracy: 0.9183 - val_loss: 0.9091 - val_accuracy: 0.6416 - 8s/epoch - 118ms/step
Epoch 4/5
72/72 - 6s - loss: 0.0999 - accuracy: 0.9694 - val_loss: 1.0722 - val_accuracy: 0.6276 - 6s/epoch - 90ms/step
Epoch 5/5
72/72 - 4s - loss: 0.0413 - accuracy: 0.9891 - val_loss: 1.4472 - val_accuracy: 0.6381 - 4s/epoch - 62ms/step
23/23 - 0s - loss: 1.4060 - accuracy: 0.6411 - 480ms/epoch - 21ms/step
Perda nos dados de teste (LSTM Bidirecional): 1.4060
Acurácia nos dados de teste (LSTM Bidirecional): 0.6411
23/23 [==============================] - 2s 15ms/step
Relatório de Classificação (LSTM Bidirecional):
Classe: 0
        Precisão: 0.6406685236768802
        Recall: 0.6424581005586593
        F1-score: 0.6415620641562064
Classe: 1
        Precisão: 0.6414565826330533
        Recall: 0.6396648044692738
        F1-score: 0.6405594405594406
Classe: macro avg
        Precisão: 0.6410625531549667
        Recall: 0.6410614525139665
        F1-score: 0.6410607523578236
```

```
Classe: weighted avg
        Precisão: 0.6410625531549669
        Recall: 0.6410614525139665
        F1-score: 0.6410607523578236
Média Macro (LSTM Bidirecional): {'precision': 0.6410625531549667, 'recall': 0.6410614525139665, 'f1-score': 0.6410607523578236, 'su
Média Ponderada (LSTM Bidirecional): {'precision': 0.6410625531549669, 'recall': 0.6410614525139665, 'f1-score': 0.6410607523578236,
```

## *ToDo*: O que você pode analisar dos modelos treinados?

```
# Análise comparativa de desempenho:

Desempenho geral:

A acurácia varia de cerca de 0.50 a 0.64 nos diferentes modelos, o que indica que eles têm um desempenho moderado na tarefa de classificação.
A perda nos dados de teste varia de aproximadamente 0.69 a 1.41, sendo mais baixa nos modelos que utilizam camadas GRU e LSTM e mais alta nos mode

Comportamento das métricas de classificação:

Em geral, vemos pelas métricas de precisão, recall e F1-score que cada classe têm desempenho razoável, com F1-scores em torno de 0.64 na maioria d
As métricas de média macro e média ponderada também mostram desempenhos similares entre os modelos, com valores em torno de 0.64.


# Análise aprofundada:
Considerando os diferentes aspectos das arquiteturas dos modelos e como eles se relacionam com a natureza da tarefa em questão.

Arquitetura dos modelos:

*   GRU (Gated Recurrent Unit): Variantes de RNNs que abordam o problema do desaparecimento do gradiente, com menos parâmetros do que LSTMs, resul
*   LSTM (Long Short-Term Memory): Projetadas para capturar dependências de longo prazo em sequências, superando o problema do desaparecimento do
*   Bidirecional: Processam sequências em ambas as direções, combinando informações contextuais de frente e trás, úteis para capturar contexto glo

Complexidade do modelo:

Apesar de mais complexos, os modelos bidirecionais e os que usam duas camadas de LSTM ou GRU não traduziram essa maior quantidade de parâmetros em

Desempenho relativo dos modelos:

*   Os modelos GRU e LSTM apresentaram desempenhos semelhantes em termos de acurácia e métricas de classificação. Isso sugere que, para o conjunto
1.   Brevidade do treinamento: O treinamento foi relativamente breve, portanto os modelos podem não ter tido tempo suficiente para aprender as nua
2.   Tamanho do conjunto de dados: O conjunto de dados utilizado para treinamento foi relativamente pequeno (5,668 tweets), os modelos podem não t
3.   Complexidade da tarefa: Considerando, no contexto de *tweets*, que a classificação de sentimentos se baseou-se mais em palavras ou frases inc

*  Os modelos bidirecionais mostraram desempenhos semelhantes em termos de acurácia geral, mas as métricas de precisão, recall e F1-score para cad
```